IGCRN 双麦克风语音增强复现实验报告

袁铮辰 | 2026-10-28 | 仓库版本 53060b3

代码与实验记录（GitHub） 原论文（Interspeech 2021）

1 任务与论文理解

目标是从两路同步带噪语音恢复麦克风 1 的目标语音，并通过独立训练的 Duplicate 对照检验第二麦克风的实际增益。声学模型为

$$x_m(t) = s(t) * h_{s,m}(t) + n(t) * h_{n,m}(t), \quad m \in \{1, 2\}, \tag{1}$$

其中 $h_{s,m}, h_{n,m}$ 是房间脉冲响应（RIR）；双通道的相位、到达时间及混合比例差异提供空间线索。评估目标 s_1 是经混响并施加与混合语音相同公共增益的 Mic1 无噪语音，不是干净源语音 s。

IGCRN 的核心是避免频率下采样以保留跨麦克风的局部相位关系。门控卷积将值分支与 sigmoid 门分支逐元素相乘：

$$Y = \mathrm{ELU}(\mathrm{BN}((W_v * X) \odot \sigma(W_g * X))) .$$

每个频点沿时间建模并共享双向 LSTM 权重；幅度由 Mask 与 Mapping 两路估计，相位单独归一化：

$$\begin{aligned} \widehat{A} &= \sigma(Z_M) \odot |X_1| + \mathrm{softplus}(Z_R), \\ \widehat{P} &= \begin{cases} (P_r + jP_i)/r, & r > \tau, \\ 1, & r \le \tau, \end{cases} \quad r = \sqrt{P_r^2 + P_i^2}, \quad \tau = 10^{-8}, \quad \widehat{S} = \widehat{A}\widehat{P}. \end{aligned} \tag{2}$$

实现中对相位范数作下界保护，并在退化时回退为单位实相位；上式为其等价的分段表达。σ 为 sigmoid，Mapping 使用 softplus。

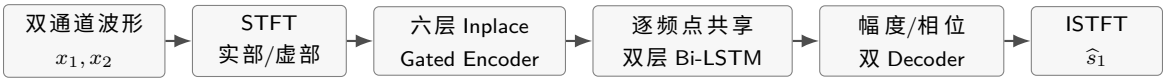


图 1: 离线推理流程：编码与递归模块不下采样频率维，最终输出单路增强波形。

2 V1 实现与训练

网络： 16 kHz、512 点 STFT、Hop 256、sqrt-Hann 窗；双麦复频谱拆为 4 个实值特征。六层 64 通道、5×1 门控卷积保持 257 个单边频点，将 $[B, 64, F, T]$ 重排为 $[BF, T, 64]$ 输入两层 Bi-LSTM；带跳连的幅度/相位解码器后接 ISTFT。总参数量 1,342,540。训练损失组合立方根压缩幅度 MSE 与压缩复频谱实/虚部 MSE。实现选用了幅度头 sigmoid/softplus、解码器末层不加 BN/ELU 等具体处理；与论文中 256 频点等差异见实现差异文档。

数据与许可	Mini LibriSpeech train-clean-5（CC BY 4.0）与 ESC-10 子集（CC BY 3.0）；先按说话人、原始噪声录音划分，再合成混合语音。
声学仿真	房间 $5 \times 5 \times 3$ m、麦距 2 cm、声源半径 1.5 m；直达声及六个一阶反射，系数 0.65。SNR 按混响后 Mic1 的语音/噪声能量定义，双通道共用噪声缩放及峰值增益。
数据规模	训练/验证/测试 600/120/120 段，每段 2 s；测试 SNR 为 $-3, 0, +3$ dB，各 40 段。
优化配置	Adam，学习率 2×10^{-4}；Batch Size 1、30 Epoch、18,000 次更新/模型；梯度裁剪 5；Colab T4，各约 55 分钟。
公平对照	Dual 输入 $[x_1, x_2]$；Duplicate 输入 $[x_1, x_1]$。相同 seed=2026、架构、数据与预算；分别从头训练，不共享训练后的权重；均采用最后一轮权重。

表 1: V1 数据、声学条件与训练配置。

复现范围： 原论文使用 AISHELL-1/TIMIT、NOISEX-92，并报告 SDR/STOI/PESQ；此处改用小规模开放数据及一阶 RIR，并报告 SI-SDR/SI-SDRi/STOI（论文 Batch Size 为 4）。因此属于模型方法及受控对照复现，不可直接对比论文数值。

3 V1 定量评估

采用标准 STOI（`extended=False`），不做时间重对齐；120 条测试样本逐句计算并等权平均。以 Mic1 无噪混响语音 s_1 为目标：

$$\text{SI-SDRi} = \text{SI-SDR}(\hat{s}_1, s_1) - \text{SI-SDR}(x_1, s_1). \tag{3}$$

方法	SI-SDR (dB)	SI-SDRi (dB)	STOI
未经处理 Mic1	0.0136	0.0000	0.7633
Dual（Mic1+Mic2）	4.6104	+4.5968	**0.7895**
Duplicate（Mic1+Mic1）	**5.1746**	**+5.1610**	0.7805

表 2: 120 条测试样本的平均结果；加粗表示两种增强模型中的较优值。

输入 SNR	Dual SI-SDRi (dB)	Duplicate SI-SDRi (dB)	Dual STOI	Duplicate STOI
−3 dB	+4.6233	+5.2298	0.7301	0.7133
0 dB	+4.5439	+5.0891	0.7973	0.7927
+3 dB	+4.6231	+5.1642	0.8412	0.8354

表 3: 按 SNR 分组的测试结果，每组 40 条。

4 结果讨论与案例分析

指标取舍：两种模型在测试集平均 SI-SDR 和 STOI 上均优于未经处理的 Mic1。Dual 比 Duplicate 的平均 SI-SDRi 低 0.5642 dB，STOI 高 0.00905，各 SNR 组趋势一致。单次实验无法判断统计显著性、听感意义或空间机制，不支持 Dual 全面更优的结论。

实际试听样本	SNR (dB)	Dual SI-SDRi (dB)	Duplicate SI-SDRi (dB)
`test_00000`	−3	+3.3162	+1.9778
`test_00001`	0	+7.2325	+5.5319
`test_00002`	+3	−0.4802	+4.5110
`test_00003`	−3	−7.3731	−1.0327

表 4: 四组实际试听案例的逐句结果（来源：原始测试 CSV）。

非盲试听（单名听者）：对表 4 四组的 Target、Mic1、Dual 和 Duplicate 逐一比较：Target 均清晰，Mic1 噪声明显。`00001` 两模型语音均可辨，Duplicate 更干净但局部发闷，Dual 有少量残噪；`00003` 中 Duplicate 降噪明显但语音减弱、部分内容缺失，Dual 仍嘈杂且语音难辨；`00002` 中 Duplicate 发闷，Dual 有残噪且音量下降；`00000` 中两模型接近，前段难辨、后段清楚。听感与 SI-SDRi 并非一一对应；上述仅为单听者非盲案例观察，并非正式评分或失效机制证明。全测试集 Dual SI-SDRi 最高为 `00067`（+17.0159 dB），最低为 `00096`（−8.2304 dB），两者仅用于定量参考，未进行试听。仍需跨种子统计、声学诊断及盲听评测。

5 推理与复验边界

Inference：Dual 加载单独训练的 Dual `last.pt`、输入 $[x_1, x_2]$；Duplicate 加载其自身的 `last.pt`、输入 $[x_1, x_1]$，使用独立训练的 Duplicate 权重，而非 Dual 的测试时输入复制。两者均经 STFT、门控编码、逐频点 Bi-LSTM、幅相解码和 ISTFT 输出增强 Mic1。双向 LSTM 依赖未来上下文，故只能称为离线整段推理。

复验边界：已保存测试 Manifest、逐句指标、Checkpoint 哈希和四组真实音频；但完整原始测试 waveform 集未归档，因此当前公开材料不足以独立重算全部 120 条历史测试指标。

V2（未正式训练）：拟以 `pyroomacoustics` 高阶 RIR 及 3000/300/300 段数据替代 V1 简化仿真；网络、损失与独立训练对照不变，不报告 V2 指标。

参考与声明：Liu & Zhang, *Inplace Gated Convolutional Recurrent Neural Network For Dual-channel Speech Enhancement*, Interspeech 2021。代码及实验记录见GitHub；AI 辅助代码、测试和文档，作者负责核验与报告。